豆瓣评论情感分类与跨文本预测报告

AI 辅助撰写。

网络书评里的星级，常被当成读者态度最直观的指标。但星级并不等于评论中每一句话的情绪。一条一星评论，可能恰好引用了书里一段动人的情节；一条五星评论，也可能列出不少缺点。这篇报告想回答一个比较窄、但可以检验的问题：如果只用一星和五星这种极端评论来训练一个按词语判断的分类器，它能不能区分豆瓣一星和五星评论？把它用到文学正文上时，它又会把什么当成“正面”或“负面”？

这个问题重要的地方，不只是最后能拿到一个多高的准确率。若把模型分数直接当成作品本身的客观情绪，或者把星级当成句子级的人工标注，模型就容易给出过度确定的结论。所以，测试集表现和跨文本预测必须分开看。

数据来自 qhchina-data 的 `datasets/classification/douban.json`，一共十万条评论，每条有 `text` 和 `label`，星级从一星到五星，各星级各两万条。本实验只保留一星和五星：一星当作负类 0，五星当作正类 1；二至四星既不训练也不测试。这样定义二元极性，能减少中间星级带来的边界问题，但任务也被限制在两个评价端点，不能说明模型真的识别了完整、连续或混合的情绪。星级是读者对一本书的总体评价，并不保证评论正文处处表达同一种态度。

抽样时按星级分别进行：每类随机取五千条训练、另取一千条测试，使用 `random_state=42`。因此训练集共一万条，测试集共两千条，同一类中的训练和测试样本不重叠。中文文本先用 jieba 切词，再用 `TfidfVectorizer` 建立特征；向量器只在训练评论上拟合词表和逆文档频率，测试集只做转换，避免测试文本参与特征拟合。特征采用默认的单词 unigram TF-IDF，关闭小写转换，也不额外去停用词。之后用逻辑回归训练分类器，最大迭代次数设为一千。也就是说，模型主要根据词语在评论中的统计关联做线性判断，并不理解整句的叙事关系。

测试准确率为 0.892，也就是两千条中正确分类一千七百八十四条。按真实类别为行、预测类别为列，并按负类 0、正类 1 排列，混淆矩阵为：负类一千条中，八百七十条判负、一百三十条误判正；正类一千条中，八十六条误判负、九百一十四条判正。也就是矩阵 `[[870, 130], [86, 914]]`。负类召回率为 87.0%，正类召回率为 91.4%；正类精确率约为 87.5%。模型对五星评论的召回略高，但仍有二百一十六条错误。这个结果说明，在随机留出的同分布极端星级评论上，词袋信号相当有用；但它不说明模型对中间星级、其他平台或文学正文也有同样可靠的判断力。

误分类显示，模型主要抓住了词面极性，却容易忽略评论者究竟在赞扬谁、否定什么。一类错误是一星评论被判为正面，共一百三十条。高置信度例子里，有评论引用关于爱情的热烈叙述，反复出现“爱”等强正向词；另有评论先写安静、优美的场景，随后才说书中缺乏可用内容。商业管理类评论也可能出现“训练有素”“有料”等看似积极的词，最终评价却是没有得到所需收获。词袋模型把被引用的情节、书中人物的言语和作者的评价混在一起，难以判断这些词是谁说的、作用范围有多大。短评若几乎没有直接评价词，也可能被少数内容词带偏。

另一类错误是五星评论被判负面，共八十六条。有读者总体很喜欢一部作品，却同时批评后半段生硬、情节挖坑；评论里“差”“强行”“不能忍”等词密集出现，模型便把局部批评

当成整体低分。也有五星评论先表达喜爱和认同，随后谈到“评分低”或“鸡汤”等负面语境词；模型只看到这些词与一星评论的统计关联，无法可靠处理转折、否定、反讽和“虽有缺点但仍喜欢”的结构。一个高置信度误例甚至反复使用“何用”“不能”等修辞，却可能是读者喜爱的诗性文字。可见错分并不只是词典漏了几个词，更是整体星级标签与局部语句情绪之间存在错位。

同一分类器随后用于《呼兰河传》正文。为避免前次处理中的边界错误，本次先排除目录、作者介绍、茅盾序、章节标题及完稿题记，只保留第一章至尾声的小说正文；按约五百字且只在句末标点处分段，共得二百零六段。每段计算正类概率减负类概率，正值表示模型更倾向五星评论，负值表示更倾向一星评论。结果有一百三十六段为正、七十段为负，平均分 0.144，中位数 0.175，范围从 -0.693 到 0.808。整体略偏正，但这只能描述模型的输出分布，不能直接推出小说整体“积极”。

分数的具体例子尤其提醒我们不要照单全收。模型最高分段之一（第 175 段，0.808）描写有二伯上吊、跳井未遂及旁人阻拦，情节显然不会因为分数高就变成欢乐场景；一个高分段（第 205 段，0.742）写冯歪嘴子看孩子拍掌而欣喜，确有局部温暖，但那只是人物当下的情绪。相反，低分段（第 137 段，-0.693）写贫困、团圆媳妇受虐及婆婆动手，负向判断与段落内容大致相合。另一个低分段（第 140 段，-0.668）围绕买红花、看病花钱与豆腐的计较展开。正负例并存说明，模型有时捕捉到局部情绪，有时却被叙事语境、人物对白或词频相关性误导。它是在用书评训练出的词语关联给小说段落打分，不是在测量文学作品的情感真值。

本实验至少有四方面限制。第一，标签来自整本书的星级，而不是评论中每个句子经人工标注的情感；把它们映射为绝对正负，会把讽刺、混合评价和情节引用压扁。第二，舍弃二至四星虽然让分类边界清楚，却造成选择偏差，准确率只适用于两极样本。第三，随机按评论切分，可能让同一书名、系列、作者或常见套语同时出现在训练与测试中；没有按书籍分组的外部测试，因此不能排除主题线索带来的乐观估计。第四，单词 TF-IDF 与线性逻辑回归不建模词序、长距离指代、否定作用域、说话人和叙事视角。正权重中出现“我们”“的”“爱”等词，负权重中出现“抄袭”“无聊”“失望”等词，既反映评论语料里的相关性，也可能带入作者、书种、书名和文体偏差。

改进应同时针对数据、评估和模型。数据层面可以纳入二至四星，区分星级预测与句子级情感标注；另抽取包含转折、反讽和引用的评论，由多人标注整体态度与局部情绪，并报告分歧。评估层面应去重、按书籍或作者分组划分训练与测试，再用不同年份、平台及文学正文作外部测试，同时报告各类精确率、召回率、F1 和置信区间，而不只给单一准确率。模型层面可以先加入双词特征、否定范围和转折特征作为可解释基线，再比较中文预训练语言模型；无论使用何种模型，都应校准概率、标出低置信段落，并保留人工复核。若任务目标是分析小说情绪弧线，更合适的参照应是对正文段落进行人工标注，并明确标注对象是叙述者、人物还是事件，而不是直接借用书评星级。当前实验的价值在于展示这种迁移能提供探索线索，也具体揭示了它何时失灵；它不能替代对文本和标签含义的判断。